

UFM-Rec: Hệ khuyến nghị sản phẩm mới trên thương mại điện tử

Proposal đồ án

Trần An Kỳ, Nguyễn Thành Phong, Nguyễn Hoàng Hải
Khoa Công nghệ Thông tin, Trường Đại học Văn Lang

Abstract—Bài toán *cold-start recommendation* vẫn là một trong những thách thức cốt lõi của hệ khuyến nghị thực tế, đặc biệt trên các sàn thương mại điện tử nơi sản phẩm mới liên tục xuất hiện nhưng chưa có đủ lượt xem, nhấp chuột hoặc mua hàng để tạo tín hiệu cộng tác ổn định. Trong khi đó, các *Foundation Model* có khả năng trích xuất tri thức ngữ nghĩa mạnh từ văn bản và hình ảnh sản phẩm, nhưng lại không phản ánh đầy đủ sở thích hành vi của người dùng. Tài liệu này đề xuất **UFM-Rec (Uncertainty-guided Foundation Model Recommendation)**, một khung hệ khuyến nghị kết hợp giữa nhánh biểu diễn ngữ nghĩa từ *Foundation Model* và nhánh mô hình hóa hành vi tuần tự của người dùng, sau đó hợp nhất hai nguồn tín hiệu bằng cơ chế thích nghi dựa trên độ bất định. Ý tưởng chính là mô hình cần biết khi nào nên tin vào tri thức ngữ nghĩa và khi nào nên tin vào tín hiệu hành vi. Proposal trình bày bối cảnh ứng dụng thực tế trong thương mại điện tử, phát biểu bài toán, kiến trúc chi tiết, hàm mất mát, kế hoạch thực nghiệm, tiêu chí đánh giá, điểm mới dự kiến và rủi ro nghiên cứu. Tất cả các con số ở phần kết quả đều là kỳ vọng nghiên cứu hoặc mục tiêu kiểm chứng, không phải kết quả đã đạt được.

Index Terms—Hệ khuyến nghị, *Foundation Model*, *cold-start recommendation*, thương mại điện tử, *uncertainty estimation*, *adaptive fusion*, *sequential recommendation*.

I. Giới thiệu

Trên các nền tảng thương mại điện tử, một sản phẩm mới có thể được đăng bán ngay hôm nay nhưng phải được khuyến nghị cho đúng nhóm khách hàng tiềm năng chỉ trong vài giờ đầu. Vấn đề là ở thời điểm này, sản phẩm gần như chưa có dữ liệu tương tác đủ lớn để các mô hình cộng tác truyền thống học được đặc trưng sở thích. Nếu hệ thống chờ đủ dữ liệu, sản phẩm sẽ mất giai đoạn tiếp cận quan trọng; nếu khuyến nghị ngẫu nhiên, trải nghiệm người dùng và tỷ lệ chuyển đổi sẽ giảm.

Các mô hình tuần tự như SASRec và BERT4Rec khai thác lịch sử tương tác của người dùng rất tốt, nhưng hiệu năng suy giảm rõ khi đối tượng khuyến nghị là *item* mới hoặc khi một phân khúc người dùng có lịch sử ngắn. Ngược lại, *Foundation Model* có thể đọc tiêu đề, mô tả, danh mục và hình ảnh

để suy ra ngữ nghĩa sản phẩm, song loại tri thức này không tương đương trực tiếp với sở thích hành vi. Một chiếc tai nghe có thể rất giống về nội dung ngữ nghĩa với một sản phẩm khác, nhưng điều đó không đảm bảo hai sản phẩm sẽ được cùng một người dùng ưa thích trong cùng ngữ cảnh.

Từ đó, câu hỏi nghiên cứu trung tâm của proposal là: “Hệ khuyến nghị có thể học cách xác định khi nào nên ưu tiên tri thức ngữ nghĩa từ *Foundation Model* và khi nào nên ưu tiên tín hiệu cộng tác từ lịch sử hành vi hay không?”

Để trả lời câu hỏi này, tài liệu đề xuất **UFM-Rec**, một khung *hybrid recommender* gồm hai nhánh chính: (i) nhánh *semantic foundation branch* dùng bộ mã hóa tiên huấn luyện để tạo biểu diễn ngữ nghĩa của sản phẩm, và (ii) nhánh *collaborative sequential branch* học sở thích tuần tự từ chuỗi tương tác. Hai nhánh được gán thêm bộ ước lượng độ bất định riêng, sau đó được hợp nhất bởi cơ chế *Uncertainty-Guided Adaptive Fusion (UGAF)*. Mục tiêu là tận dụng thế mạnh của từng loại tín hiệu tùy theo điều kiện dữ liệu thực tế.

II. Bài toán ứng dụng thực tế

A. Bối cảnh

Bài toán áp dụng được chọn là **khuyến nghị sản phẩm mới trên sàn thương mại điện tử**. Hệ thống nhận đầu vào là lịch sử người dùng tương tác với sản phẩm (xem, nhấp, thêm giỏ, mua), cùng với metadata của sản phẩm như tiêu đề, mô tả, danh mục, thương hiệu, giá và hình ảnh. Đầu ra là danh sách Top- K sản phẩm phù hợp nhất cho mỗi người dùng tại thời điểm dự đoán.

B. Động cơ thực tiễn

Trong thực tế, sản phẩm mới chiếm tỷ lệ đáng kể ở các ngành hàng có tốc độ cập nhật nhanh như thời trang, điện tử tiêu dùng, phụ kiện, mỹ phẩm và đồ gia dụng. Vì vậy, một hệ khuyến nghị thực tiễn cần thỏa ba yêu cầu:

- **Hiệu quả với cold-start:** hoạt động được khi item có rất ít hoặc chưa có tương tác.

- **Khai thác đa phương thức:** tận dụng mô tả văn bản và ảnh sản phẩm để tăng khả năng khái quát.
- **Đánh tin cậy và thích nghi:** không áp dụng một trọng số hợp nhất cố định cho mọi trường hợp.

C. Phát biểu bài toán

Gọi $\mathcal{U}$ là tập người dùng và $\mathcal{I}$ là tập sản phẩm. Với mỗi người dùng $u \in \mathcal{U}$, ta có chuỗi tương tác theo thời gian:

$$S_u = [i_1, i_2, \dots, i_T], \quad i_t \in \mathcal{I}. \quad (1)$$

Mỗi sản phẩm i có metadata văn bản x_i^{txt} và dữ liệu hình ảnh x_i^{img} . Mục tiêu là ước lượng xác suất hoặc điểm xếp hạng cho sản phẩm tiếp theo:

$$\hat{y}_{u,i} = f(u, S_u, x_i^{txt}, x_i^{img}), \quad (2)$$

để sinh ra tập khuyến nghị Top- K cho người dùng u .

Khó khăn chính là với các sản phẩm mới, số tương tác n_i rất nhỏ hoặc bằng 0:

$$n_i \in \{0, 1, \dots, c\}, \quad c \text{ nhỏ}. \quad (3)$$

Khi đó, biểu diễn cộng tác z_i^{cf} thiếu ổn định, trong khi biểu diễn ngữ nghĩa z_i^{sem} có thể vẫn hữu ích. Do đó, hệ thống cần một cơ chế xác định trọng số hợp nhất theo *độ tin cậy* của từng nguồn tín hiệu.

III. Khoảng trống nghiên cứu và đóng góp dự kiến

A. Khoảng trống nghiên cứu

Nhiều hướng nghiên cứu hiện nay rơi vào một trong ba kiểu: (i) chỉ dùng mô hình cộng tác/tuần tự, (ii) chỉ dùng biểu diễn ngữ nghĩa từ văn bản/ảnh, hoặc (iii) hợp nhất hai loại đặc trưng bằng cách nối vector hoặc dùng trọng số tĩnh. Những cách này có các hạn chế sau:

- Không mô hình hóa rõ ràng **độ bất định** của từng nhánh biểu diễn.
- Chưa trả lời được câu hỏi *khi nào* nên tin vào Foundation Model hơn tín hiệu hành vi, đặc biệt ở các mức cold-start khác nhau.
- Nhiều mô hình dùng Foundation Model nhưng chưa tối ưu cho ràng buộc phần cứng tầm trung, ví dụ GPU 16 GB.
- Hầu hết bài toán chỉ báo cáo chỉ số xếp hạng mà chưa quan tâm đúng mức đến **calibration** và **reliability** của đầu ra.

B. Đóng góp dự kiến

Proposal kỳ vọng bốn đóng góp cốt lõi:

- 1) Đề xuất khung **UFM-Rec** kết hợp *Foundation Model* với *sequential recommendation* cho bài toán cold-start trong thương mại điện tử.
- 2) Xây dựng cơ chế **Dual Uncertainty Estimation** để ước lượng riêng độ bất định của biểu diễn cộng tác và ngữ nghĩa.
- 3) Thiết kế mô-đun **UGAF** để hợp nhất hai nguồn tín hiệu bằng trọng số thích nghi theo độ tin cậy thay vì trọng số cố định.
- 4) Đánh giá không chỉ ở các chỉ số xếp hạng mà còn ở góc nhìn **hiệu năng theo từng regime cold-start, ablation và calibration**.

IV. Phương pháp đề xuất

A. Tổng quan kiến trúc

Hình 1 mô tả kiến trúc tổng thể của UFM-Rec. Hệ thống gồm sáu thành phần chính:

- 1) **Input & Data:** chuỗi tương tác người dùng, metadata văn bản và ảnh sản phẩm.
- 2) **Semantic Foundation Branch:** nhánh trích xuất tri thức ngữ nghĩa bằng bộ mã hóa văn bản/hình ảnh đã tiền huấn luyện.
- 3) **Collaborative Sequential Branch:** nhánh học sở thích hành vi theo chuỗi thời gian.
- 4) **Dual Uncertainty Estimation:** bộ ước lượng độ bất định cho hai nhánh.
- 5) **UGAF:** hợp nhất thích nghi dựa trên độ bất định.
- 6) **Recommendation Head:** tăng tính điểm và sinh Top- K sản phẩm.

B. Nhánh biểu diễn ngữ nghĩa từ Foundation Model

Với mỗi sản phẩm i , văn bản mô tả và ảnh sản phẩm được mã hóa thành vector ngữ nghĩa:

$$h_i^{txt} = E_{txt}(x_i^{txt}), \quad h_i^{img} = E_{img}(x_i^{img}). \quad (4)$$

Ở đây E_{txt} có thể là bộ mã hóa văn bản kiểu LLM/Transformer, còn E_{img} có thể là bộ mã hóa ảnh kiểu CLIP/VLM. Hai đặc trưng được chiếu về cùng không gian và kết hợp thông qua *adapter* hoặc LoRA:

$$z_i^{sem} = A([h_i^{txt}, h_i^{img}]) \in \mathbb{R}^d. \quad (5)$$

Do mục tiêu thực nghiệm hướng tới GPU 16 GB, proposal ưu tiên chiến lược *parameter-efficient fine-tuning* thay vì tinh chỉnh toàn bộ Foundation Model.




Fig. 1. Kiến trúc tổng thể của đề xuất UFM-Rec. Sơ đồ thể hiện luồng xử lý từ dữ liệu đầu vào, nhánh Foundation Model, nhánh mô hình hóa hành vi tuần tự, khối ước lượng độ bất định, cơ chế hợp nhất thích nghi UGAF và đầu ra Top-K khuyến nghị.

C. Nhánh cộng tác tuần tự

Lịch sử tương tác của người dùng được biến đổi thành chuỗi embedding item và position:

$$X_u = [e_{i_1} + p_1, e_{i_2} + p_2, \dots, e_{i_T} + p_T]. \quad (6)$$

Một mô hình tuần tự như SASRec hoặc BERT4Rec được dùng để học biểu diễn ngữ cảnh hành vi:

$$z_u^{cf} = G(X_u), \quad z_i^{cf} = \phi(z_u^{cf}, i). \quad (7)$$

Trong đó ϕ là phép chiếu hoặc cơ chế scoring để biểu diễn mức phù hợp của item i với ngữ cảnh sở thích gần nhất của người dùng.

D. Ước lượng độ bất định kép

Độ bất định được học riêng cho hai nhánh:

$$u_{cf} = \text{Softplus}(\text{MLP}_{cf}(z^{cf})), \quad (8)$$

$$u_{sem} = \text{Softplus}(\text{MLP}_{sem}(z^{sem})). \quad (9)$$

Ta quy đổi độ bất định thành độ tin cậy:

$$r_{cf} = \exp(-u_{cf}), \quad r_{sem} = \exp(-u_{sem}). \quad (10)$$

Trọng số hợp nhất thích nghi được xác định bởi:

$$\alpha = \frac{r_{cf}}{r_{cf} + r_{sem}}. \quad (11)$$

Diễn giải trực quan: nếu nhánh cộng tác kém chắc chắn (ví dụ item mới, ít tương tác), u_{cf} tăng và α giảm; khi đó mô hình dựa nhiều hơn vào tri thức ngữ nghĩa. Ngược lại, với item phổ biến hoặc lịch sử dày, nhánh cộng tác đáng tin cậy hơn và α tăng.

E. Hợp nhất thích nghi UGAF

Như Hình 2, ngoài trọng số α , mô-đun UGAF còn học đặc trưng căn chỉnh chéo giữa hai không gian biểu diễn:

$$z_{align} = \sigma(\text{MLP}([z^{cf}; z^{sem}])) \odot W[z^{cf}; z^{sem}], \quad (12)$$

trong đó σ là hàm sigmoid và $\odot$ là phép nhân từng phần tử. Vector hợp nhất cuối cùng được xác định bởi:

$$z^{fused} = \alpha z^{cf} + (1 - \alpha) z^{sem} + z_{align}. \quad (13)$$

Vector z^{fused} sau đó đi qua tầng chấm điểm để tính điểm cho toàn bộ candidate item:

$$s(u, i) = \text{MLP}(z^{fused}, e_i). \quad (14)$$

F. Hàm mất mát

Tổng hàm mục tiêu được đề xuất là:

$$\mathcal{L}_{total} = \mathcal{L}_{BPR} + \lambda_1 \mathcal{L}_{align} + \lambda_2 \mathcal{L}_{unc} + \lambda_3 \mathcal{L}_{cal}. \quad (15)$$

Trong đó:

- $\mathcal{L}_{BPR}$: tối ưu ranking từ implicit feedback.
- $\mathcal{L}_{align}$: giữ nhất quán ở mức vừa phải giữa đặc trưng hành vi và ngữ nghĩa.
- $\mathcal{L}_{unc}$: regularization cho độ bất định, tránh bùng nổ giá trị.
- $\mathcal{L}_{cal}$: cải thiện độ calibration giữa độ tin cậy dự đoán và xác suất phù hợp thực sự.




Fig. 2. Kiến trúc chi tiết của mô-đun UGAF. Mô-đun chuyển độ bất định thành độ tin cậy, chuẩn hóa thành trọng số hợp nhất, mô hình hóa tương tác chéo giữa hai không gian biểu diễn và sinh vector hợp nhất cuối cùng dùng cho chấm điểm khuyến nghị.

G. Giải mã ở mức thuật toán

- Bước 1:** Thu thập chuỗi tương tác người dùng và metadata sản phẩm.
- Bước 2:** Mã hóa văn bản và ảnh sản phẩm để tạo z^{sem} .
- Bước 3:** Mã hóa chuỗi tương tác người dùng để tạo z^{cf} .
- Bước 4:** Ước lượng u_{sem} và u_{cf} .
- Bước 5:** Tính độ tin cậy r_{sem}, r_{cf} và trọng số α .
- Bước 6:** Tính z_{align} và tạo z^{fused} .
- Bước 7:** Chấm điểm candidate item, tối ưu theo $\mathcal{L}_{total}$.
- Bước 8:** Suy diễn Top-K sản phẩm cho từng người dùng.

V. Thiết kế thực nghiệm

A. Bộ dữ liệu

Proposal đề xuất dùng ít nhất hai nhóm dữ liệu:

- **Amazon Reviews / Amazon Product Data:** phù hợp nhất với bối cảnh thương mại điện tử vì có lịch sử tương tác và metadata phong phú.
- **MovieLens-1M hoặc một tập nhỏ tương tự:** dùng để kiểm thử pipeline và đối chiếu nền tảng trước khi mở rộng sang dữ liệu đa phương thức phức tạp hơn.

Dữ liệu được chia theo thời gian để phản ánh đúng bối cảnh online recommendation. Item được gom thành các regime sau:

$$\text{Zero-shot: } n_i = 0; \quad \text{Extreme cold: } 1 \leq n_i \leq 5; \quad (16)$$

$$\text{Cold: } 6 \leq n_i \leq 20; \quad \text{Warm: } n_i > 20. \quad (17)$$

B. Baseline so sánh

- **Collaborative baselines:** MF/BPR, SASRec, BERT4Rec.
- **Content-aware baselines:** mô hình dùng text-only hoặc image-only.
- **Hybrid baselines:** nối vector hoặc weighted sum với trọng số cố định.
- **Foundation-model baselines:** mô hình dùng embedding từ encoder tiền huấn luyện nhưng không có uncertainty-guided fusion.

C. Chỉ số đánh giá

Các chỉ số chính gồm Recall@K, NDCG@K, Hit Rate@K, MRR@K. Bên cạnh đó, proposal đề xuất kiểm tra:

- **Cold-start breakdown:** hiệu năng theo từng regime của số tương tác.
- **Calibration:** ECE hoặc mối tương quan giữa độ tin cậy và độ chính xác.
- **Efficiency:** số tham số cập nhật, thời gian huấn luyện, bộ nhớ GPU và throughput suy diễn.

TABLE I
Thiết kế đánh giá và tiêu chí kiểm chứng

Hạng mục	Nội dung	Mục đích	Kỳ vọng
So sánh chính	UFM-Rec so với SASRec, BERT4Rec, hybrid đơn giản	Kiểm tra hiệu quả tổng thể trên toàn bộ tập kiểm tra	Tốt hơn hoặc ít nhất cạnh tranh
Cold-start breakdown	Đánh giá riêng trên zero-shot / extreme cold / cold / warm	Kiểm tra tính thích nghi theo số lượng tương tác	Cải thiện rõ ở zero-shot và extreme cold
Ablation A	Bỏ uncertainty estimation	Kiểm tra vai trò của độ bất định	Hiệu năng giảm, đặc biệt ở cold-start
Ablation B	Dùng fusion cố định thay cho UGAF	Kiểm tra vai trò của trọng số thích nghi	Hiệu năng và calibration giảm
Ablation C	Chỉ dùng semantic hoặc chỉ dùng collaborative	Xác minh lợi ích bổ sung lẫn nhau	Mô hình một nhánh yếu hơn rõ rệt
Efficiency	Đo thời gian, VRAM, số tham số trainable	Đảm bảo khả thi trên GPU 16 GB	Huấn luyện ổn định với PEFT

VI. Kết quả kỳ vọng và tiêu chí chấp nhận

Phần này được trình bày như **kết quả kỳ vọng**, không phải kết quả đã thực nghiệm.

A. Các giả thuyết nghiên cứu

- **H1:** Nhánh semantic mạnh hơn nhánh collaborative trong bối cảnh zero-shot hoặc extreme cold-start.
- **H2:** Nhánh collaborative mạnh hơn semantic khi item đã có dữ liệu tương tác dày.
- **H3:** UFM-Rec vượt trội hơn từng nhánh đơn lẻ nhờ hợp nhất thích nghi.
- **H4:** Dual uncertainty estimation giúp cải thiện calibration và độ ổn định của mô hình.
- **H5:** PEFT cho Foundation Model đem lại cân bằng tốt giữa hiệu quả và chi phí tính toán.

B. Ngưỡng mục tiêu

Một proposal nghiêm túc nên nêu ngưỡng kiểm chứng thay vì chỉ nói “mong đợi tốt hơn”. Tài liệu này đề xuất các ngưỡng chấp nhận như sau:

- Cải thiện tương đối khoảng 3%–8% về NDCG@10 hoặc Recall@10 so với baseline mạnh nhất trong nhóm cold-start.
- Trên regime warm, hiệu năng không được giảm đáng kể (ví dụ giảm dưới 1% so với mô hình cộng tác mạnh nhất).
- ECE hoặc thước đo calibration tương đương phải tốt hơn so với phương án fusion cố định.
- Số tham số cập nhật phải nhỏ hơn rõ rệt so với full fine-tuning, đủ để chạy thực nghiệm chính trên GPU 16 GB.

C. Kết quả định tính kỳ vọng

Kỳ vọng quan trọng không chỉ nằm ở giá trị metric, mà còn ở hình thái hành vi của mô hình:

- Với item mới, mô hình gán trọng số thấp hơn cho nhánh cộng tác và ưu tiên ngữ nghĩa.
- Với item phổ biến, mô hình dịch chuyển dần sang nhánh cộng tác.
- Trọng số hợp nhất biến thiên mượt theo độ phong phú của dữ liệu, không dao động bất thường.

VII. Điểm mới (Novelty)

Novelty của proposal được tóm gọn thành bốn ý:

- 1) **Novelty về bài toán:** thay vì chỉ dùng Foundation Model để tăng thêm đặc trưng, proposal đặt câu hỏi ở mức cao hơn: “Khi nào hệ khuyến nghị nên tin vào Foundation Model?”
- 2) **Novelty về phương pháp:** học đồng thời hai biểu diễn dị thể (semantic và collaborative), gán thêm uncertainty estimation và fusion thích nghi.
- 3) **Novelty về đánh giá:** xem xét hiệu năng theo các regime cold-start thay vì chỉ báo cáo trung bình toàn tập.
- 4) **Novelty về tính thực dụng:** thiết kế phù hợp với PEFT và phần cứng tầm trung, tăng cơ hội hiện thực hóa nghiên cứu.

VIII. Kế hoạch triển khai

- **Giai đoạn 1:** Chuẩn hóa dữ liệu, xây pipeline huấn luyện cơ bản với SASRec/BERT4Rec.
- **Giai đoạn 2:** Tích hợp bộ mã hóa ngữ nghĩa và adapter/LoRA.
- **Giai đoạn 3:** Xây dựng uncertainty heads và mô-đun UGAF.
- **Giai đoạn 4:** Thực nghiệm, tuning hyperparameter, phân tích ablation.

- **Giai đoạn 5:** Viết báo cáo, trực quan hóa kết quả và hoàn thiện bản thảo paper.

IX. Rủi ro và hướng xử lý

- **Rủi ro 1:** embedding từ Foundation Model quá mạnh làm lấn át tín hiệu hành vi. *Giải pháp:* regularization và calibration cho gate.
- **Rủi ro 2:** metadata không đồng nhất, ảnh hoặc mô tả nhiều. *Giải pháp:* làm sạch dữ liệu, cắt ngắn mô tả, chuẩn hóa trường danh mục.
- **Rủi ro 3:** chi phí huấn luyện cao. *Giải pháp:* dùng encoder đóng băng, chỉ cập nhật adapter và các head nhỏ.
- **Rủi ro 4:** hiệu năng warm-start giảm nhẹ. *Giải pháp:* thêm ràng buộc không để trọng số semantic lấn át khi collaborative đã đủ tin cậy.

X. Kết luận

Proposal đã cụ thể hóa một hướng nghiên cứu Foundation Model cho hệ khuyến nghị dưới dạng bài toán thực tế: khuyến nghị sản phẩm mới trên thương mại điện tử. Thay vì chỉ ghép thêm đặc trưng ngữ nghĩa vào recommender, UFM-Rec đề xuất một góc nhìn mạnh hơn: khai thác **độ bất định** để quyết định cách hợp nhất giữa tri thức ngữ nghĩa và tín hiệu hành vi. Nếu được kiểm chứng thành công, mô hình không chỉ cải thiện cold-start recommendation mà còn tạo ra một khung nghiên cứu có thể mở rộng sang cross-domain recommendation, multi-modal recommendation và continual recommendation.

Lưu ý học thuật

Bản PDF này là **proposal nghiên cứu**. Các mục “kết quả kỳ vọng”, “ngưỡng mục tiêu” và “giả thuyết” không được hiểu là kết quả đã đạt. Khi chuyển sang manuscript thực nghiệm, các nội dung này cần được thay bằng số liệu, biểu đồ và kiểm định thực tế.

References

- [1] W.-C. Kang and J. McAuley, “Self-Attentive Sequential Recommendation,” in *Proc. IEEE ICDM*, 2018.
- [2] F. Sun, J. Liu, J. Wu, C. Pei, X. Lin, W. Ou, and P. Jiang, “BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer,” in *Proc. ACM CIKM*, 2019.
- [3] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme, “BPR: Bayesian Personalized Ranking from Implicit Feedback,” in *Proc. UAI*, 2009.
- [4] A. Radford *et al.*, “Learning Transferable Visual Models From Natural Language Supervision,” in *Proc. ICML*, 2021.
- [5] E. J. Hu *et al.*, “LoRA: Low-Rank Adaptation of Large Language Models,” in *Proc. ICLR*, 2022.
- [6] J. McAuley, C. Targett, J. Shi, and A. van den Hengel, “Image-Based Recommendations on Styles and Substitutes,” in *Proc. ACM SIGIR*, 2015.
- [7] Y. Li, H. Zhang, X. Wang, and T. Chen, “Foundation Models for Recommender Systems: A Survey,” *arXiv preprint arXiv:2405.11811*, 2024.

- [8] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, “On Calibration of Modern Neural Networks,” in *Proc. ICML*, 2017.